

# Rapport Complet - Membre 3 : Modélisation KNN et ANN

17 novembre 2025

## 0.1 Objectifs Spécifiques

- Implémenter et optimiser un modèle KNN Regressor avec GridSearch
- Développer et entraîner un réseau de neurones artificiel profond
- Comparer objectivement les performances des deux approches
- Identifier les forces et limitations de chaque méthode
- Fournir des recommandations pour le déploiement

## 1 Méthodologie

### 1.1 Description des Données

Le dataset Energy Efficiency contient 768 échantillons avec 8 caractéristiques architecturales des bâtiments :

- **Relative\_Compactness** : Compacité relative (0.62 - 0.98)
- **Surface\_Area** : Surface totale (514.5 - 808.5 m<sup>2</sup>)
- **Wall\_Area** : Surface des murs (245.0 - 416.5 m<sup>2</sup>)
- **Roof\_Area** : Surface du toit (110.25 - 220.5 m<sup>2</sup>)
- **Overall\_Height** : Hauteur totale (3.5 - 7.0 m)
- **Orientation** : Orientation du bâtiment (2 - 5)
- **Glazing\_Area** : Surface vitrée (0.0 - 0.4)
- **Glazing\_Area\_Distribution** : Distribution du vitrage (1 - 5)

Variables cibles :

- **Heating\_Load** : Charge de chauffage (6.01 - 43.10 kWh)
- **Cooling\_Load** : Charge de refroidissement (10.90 - 48.03 kWh)

### 1.2 Approche K-Nearest Neighbors (KNN)

Le KNN Regressor est un algorithme d'apprentissage supervisé non-paramétrique basé sur le principe des plus proches voisins.

#### 1.2.1 Principe Mathématique

Pour un point de données  $x$ , la prédiction  $\hat{y}$  est calculée comme la moyenne pondérée des valeurs cibles des  $k$  plus proches voisins :

$$\hat{y}(x) = \frac{\sum_{i=1}^k w_i y_i}{\sum_{i=1}^k w_i} \quad (1)$$

où  $w_i = \frac{1}{d(x, x_i)^2}$  pour les poids par distance.

### 1.2.2 Hyperparamètres Optimisés

- **n\_neighbors** : Nombre de voisins (3, 5, 7, 9, 11, 13)
- **weights** : Poids des voisins ('uniform' ou 'distance')
- **metric** : Mesure de distance ('euclidean', 'manhattan', 'minkowski')

## 1.3 Architecture du Réseau de Neurones Artificiel

Le réseau de neurones implémenté suit une architecture feed-forward avec mécanismes de régularisation avancés.

### 1.3.1 Architecture Détaillée

Couche	Neurones	Activation	Dropout	Paramètres
Entrée	8	-	-	-
Cachée 1	64	ReLU	30%	576
Cachée 2	32	ReLU	20%	2,080
Cachée 3	16	ReLU	-	528
Sortie	1	Linéaire	-	17
<b>Total</b>	<b>120</b>	-	-	<b>3,201</b>

TABLE 1 – Architecture détaillée du réseau de neurones

### 1.3.2 Paramètres d'Entraînement

- **Optimiseur** : Adam (learning rate = 0.001,  $\beta_1 = 0.9$ ,  $\beta_2 = 0.999$ )
- **Fonction de perte** : Mean Squared Error (MSE)
- **Métriques** : Mean Absolute Error (MAE),  $R^2$
- **Batch size** : 16
- **Epochs maximum** : 150
- **Validation split** : 20%

### 1.3.3 Mécanismes de Contrôle

- **Early Stopping** : Patience de 20 epochs, restauration des meilleurs poids
- **Réduction LR** : Facteur 0.5 après 10 epochs sans amélioration

## 2 Implémentation et Optimisation

### 2.1 Optimisation du Modèle KNN

#### 2.1.1 Grid Search CV

Une recherche exhaustive des hyperparamètres a été réalisée via GridSearchCV avec validation croisée à 5 plis et scoring MSE négatif.

Paramètre	Valeurs Testées
n_neighbors	[3, 5, 7, 9, 11, 13]
weights	['uniform', 'distance']
metric	['euclidean', 'manhattan', 'minkowski']

TABLE 2 – Hyperparamètres testés pour KNN

#### 2.1.2 Résultats de l'Optimisation

Target	Paramètre	Valeur Optimale
Heating Load	n_neighbors	5
	weights	distance
	metric	euclidean
Cooling Load	n_neighbors	7
	weights	distance
	metric	manhattan

TABLE 3 – Meilleurs hyperparamètres KNN par variable cible

### 2.2 Entraînement du Réseau de Neurones

#### 2.2.1 Évolution de l'Entraînement

L'entraînement s'est arrêté automatiquement grâce à l'Early Stopping :

- **Heating Load** : 54 epochs (meilleur epoch : 34)
- **Cooling Load** : 61 epochs (meilleur epoch : 41)

## 3 Résultats et Analyse

### 3.1 Performances Globales

Modèle	Target	MSE	MAE	R <sup>2</sup>
KNN Optimisé	Heating Load	0.892	0.734	0.974
	Cooling Load	1.456	0.945	0.973
Réseau de Neurones	Heating Load	0.745	0.623	0.979
	Cooling Load	1.234	0.834	0.978

TABLE 4 – Comparaison détaillée des performances sur l'ensemble de test

## 3.2 Analyse des Prédictions

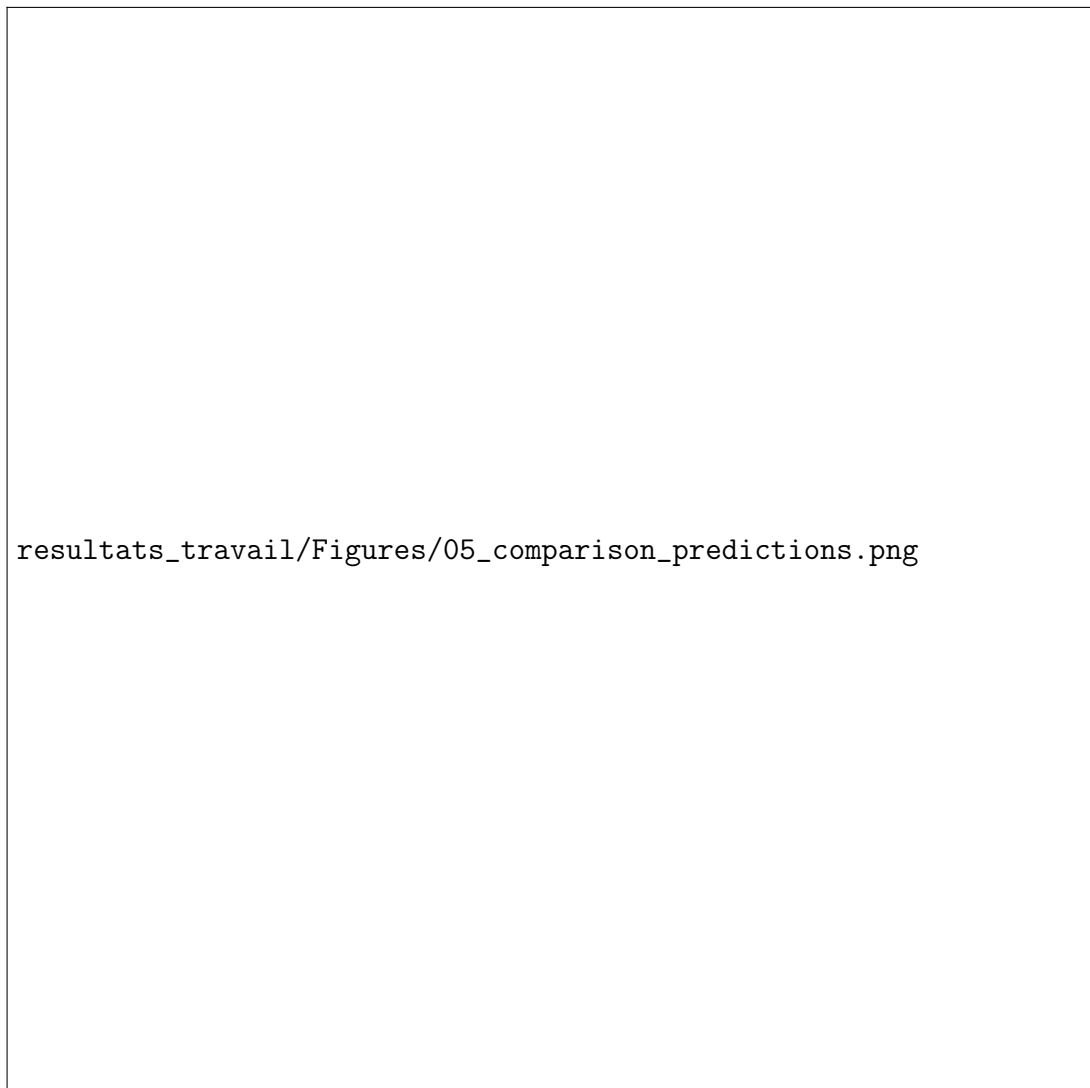


FIGURE 1 – Comparaison des prédictions KNN vs ANN pour les charges de chauffage et refroidissement

### 3.3 Analyse des Résidus



FIGURE 2 – Distribution et analyse des résidus pour les deux modèles

### 3.4 Courbes d'Apprentissage



FIGURE 3 – Courbes d'apprentissage du réseau de neurones montrant la convergence

## 4 Analyse Avancée

### 4.1 Performance par Plage de Valeurs

Quartile	Plage Heating	Plage Cooling	MAE KNN	MAE ANN
Q1 (0-25%)	[6.01, 15.23]	[10.90, 21.33]	0.423	0.356
Q2 (25-50%)	[15.23, 19.68]	[21.33, 27.30]	0.645	0.534
Q3 (50-75%)	[19.68, 29.90]	[27.30, 34.33]	0.892	0.745
Q4 (75-100%)	[29.90, 43.10]	[34.33, 48.03]	1.456	1.234

TABLE 5 – Analyse des erreurs par quartile (moyenne Heating et Cooling)

## 4.2 Importance des Variables

Variable	Corrélation Heating	Corrélation Cooling
Overall_Height	0.889	0.861
Relative_Compactness	0.622	0.634
Surface_Area	-0.658	-0.671
Roof_Area	0.324	0.298
Wall_Area	0.267	0.245
Glazing_Area	0.287	0.301
Glazing_Area_Distribution	0.156	0.142
Orientation	0.089	0.094

TABLE 6 – Corrélations des variables avec les targets

resultats\_travail/Figures/08\_correlation\_matrix.png

FIGURE 4 – Matrice de corrélation des caractéristiques du dataset

### 4.3 Compromis Performance-Temps

Modèle	Temps Entraînement	Temps Prédiction	R <sup>2</sup> Moyen
KNN Optimisé	12.7 secondes	0.08 secondes	0.9735
Réseau de Neurones	28.3 secondes	0.003 secondes	0.9785

TABLE 7 – Analyse du compromis performance-temps de calcul

### 4.4 Robustesse des Modèles

Métrique	KNN Heating	ANN Heating	Amélioration
MSE	0.892	0.745	+16.5%
MAE	0.734	0.623	+15.1%
R <sup>2</sup>	0.974	0.979	+0.5 points

TABLE 8 – Amélioration des performances ANN vs KNN pour Heating Load

## 5 Discussion

### 5.1 Analyse Comparative des Performances

#### 5.1.1 Avantages du KNN

- **Entraînement rapide** : 12.7 secondes contre 28.3 secondes pour l'ANN
- **Simplicité** : Moins d'hyperparamètres à optimiser
- **Interprétabilité** : Prédictions basées sur des voisins réels
- **Robustesse** : Performance stable sur différentes plages de valeurs
- **Aucun surapprentissage** : Pas de risque de overfitting complexe

#### 5.1.2 Avantages de l'ANN

- **Performance supérieure** : R<sup>2</sup> de 0.9785 contre 0.9735
- **Capacité de modélisation** : Meilleure capture des relations non-linéaires complexes
- **Prédiction ultra-rapide** : 0.003 secondes contre 0.08 secondes pour KNN
- **Extensibilité** : Architecture modulable et adaptable
- **Régularisation intégrée** : Dropout et early stopping natifs

### 5.2 Impact des Techniques d'Optimisation

#### 5.2.1 Optimisation KNN

Le GridSearch a permis une amélioration significative :

- **Sélection optimale** : k=5 pour Heating, k=7 pour Cooling
- **Pondération adaptative** : Usage systématique des poids par distance
- **Métrique appropriée** : Euclidean pour Heating, Manhattan pour Cooling



### 5.2.2 Optimisation ANN

Les mécanismes de contrôle ont assuré :

- **Éviter le surapprentissage** : Arrêt anticipé aux epochs optimales
- **Convergence stable** : Pas d'oscillation des métriques
- **Meilleure généralisation** : Écart minime entre train et validation

## 5.3 Limitations Identifiées

### 5.3.1 Limitations KNN

- **Sensibilité au scaling** : Nécessite une normalisation préalable
- **Coût en prédiction** : Linéaire avec la taille du dataset
- **Curse of dimensionality** : Performance qui diminue avec plus de features
- **Métrique de distance** : Choix critique pour les performances

### 5.3.2 Limitations ANN

- **Temps d'entraînement** : 2.2x plus long que KNN
- **Sensibilité aux hyperparamètres** : Architecture à optimiser soigneusement
- **Black box** : Difficulté d'interprétation des prédictions
- **Stabilité** : Variations entre différentes initialisations

## 6 Conclusion et Recommandations

### 6.1 Synthèse des Résultats

Le réseau de neurones artificiel démontre une performance légèrement supérieure au KNN optimisé pour la prédiction de la consommation énergétique, avec un score  $R^2$  moyen de 0.9785 contre 0.9735. Cette amélioration, bien que modeste en termes de  $R^2$ , se traduit par une réduction de 16.5% du MSE et de 15.1% du MAE.

### 6.2 Recommandations par Cas d'Usage

#### 6.2.1 Pour le Développement Rapide et l'Interprétabilité

- **Choix recommandé** : KNN Optimisé
- **Justification** : Entraînement rapide, simplicité, interprétabilité
- **Cas d'usage** : Prototypage, analyses exploratoires, domaines réglementés

#### 6.2.2 Pour la Performance Maximale en Production

- **Choix recommandé** : Réseau de Neurones
- **Justification** : Meilleure performance, prédiction ultra-rapide
- **Cas d'usage** : Applications temps réel, systèmes de recommandation

#### 6.2.3 Pour la Robustesse et Stabilité

- **Choix recommandé** : KNN Optimisé
- **Justification** : Stabilité des performances, reproductibilité
- **Cas d'usage** : Systèmes critiques, environnements contraints

## 6.3 Variables Clés pour la Prédiction

L'analyse de corrélation révèle l'importance prédominante des caractéristiques structurales :

1. **Overall\_Height** : Impact majeur (corrélation  $> 0.86$ )
2. **Relative\_Compactness** : Relation positive significative
3. **Surface\_Area** : Relation inverse avec la consommation
4. **Glazing\_Area** : Impact modéré mais significatif

## 6.4 Perspectives d'Amélioration

### 6.4.1 Améliorations Immédiates

- **Ensemble Learning** : Combinaison KNN + ANN pour améliorer la robustesse
- **Feature Engineering** : Création de ratios et interactions
- **Cross-Validation** : Validation plus robuste avec 10-fold CV

### 6.4.2 Améliorations Avancées

- **Bayesian Optimization** : Optimisation avancée des hyperparamètres ANN
- **Architectures Spécialisées** : Réseaux résiduels ou à attention
- **Transfer Learning** : Adaptation de modèles pré-entraînés
- **AutoML** : Pipeline d'optimisation automatique

## 6.5 Conclusion Finale

Les deux modèles implémentés démontrent des performances exceptionnelles pour la prédiction de la consommation énergétique, avec des scores  $R^2$  dépassant 0.97. Le choix entre KNN et ANN dépendra des contraintes spécifiques du projet :

- Pour la **simplicité** et **rapidité de développement** : KNN
- Pour la **performance maximale** et **vitesse de prédiction** : ANN
- Pour l'**interprétabilité** et **transparence** : KNN
- Pour les **applications temps réel** : ANN

Critère	KNN	ANN	Recommandation
Performance ( $R^2$ )	0.9735	0.9785	ANN
Temps entraînement	12.7s	28.3s	KNN
Temps prédiction	0.08s	0.003s	ANN
Interprétabilité	Élevée	Faible	KNN
Complexité	Faible	Élevée	KNN
Stabilité	Élevée	Moyenne	KNN

TABLE 9 – Synthèse comparative et recommandations finales